Trabalho da Unidade 3 — Processamento de Linguagem Natural

Integrantes:
Felipe Giovanella
Pedro Albuquerque
Gustavo Campestrini
Nicolas Ceruti

Metodologia e delimitação

A base fornecida contém 500 registros e as colunas `id`, `titulo`, `secao`, `publicado_em`, `url`, `texto_normalizado`, `tokens_sem_stopwords`, `stems`, `lemas`, `quantidade_tokens` e `quantidade_tokens_limpos`. Para os experimentos com representação de palavras, utilizamos título + lemas; para a avaliação inicial de sentimentos e reconhecimento de entidades, reutilizamos o notebook da Aula 9 executado anteriormente (15 e 25 notícias, respectivamente). Em todos os novos experimentos utilizamos a semente 42. Os scripts e notebooks anexos permitem reprodução.

Importante: o corpus enviado é um CSV já processado. O campo `texto_normalizado` está em minúsculas e não é idêntico ao texto jornalístico original; isso pode afetar NER, parsing e extração de relações. A versão original do texto é preferível para uma avaliação definitiva.

1. Checklist de técnicas efetivamente realizadas

Técnica	BoW	TF-IDF	Word2Vec	BERTimbau
Clusterização + PCA / visualização	✔ Executado	✔ Executado	✔ Executado	Pendente de executar
Busca / recomendação	✔ Executado	✔ Executado	✔ Executado	Pendente de executar
Classificação supervisionada	✔ Executado	✔ Executado	✔ Executado	Pendente de executar

- **Análise de sentimentos:** ✔ Executada anteriormente com 15 notícias e XLM-RoBERTa; nova versão do notebook configurada para 100, ainda sem nova execução validada.
- **Reconhecimento de Entidades Nomeadas (NER):** ✔ Executado com spaCy em 25 notícias.
- **Extração de relações:** ✔ Executada por regras sintáticas em 25 notícias, produzindo **candidatos** a relações; pendente revisão manual de qualidade.
- **BERTimbau:** incluído no código e nos procedimentos de comparação, mas sem resultados computados e verificados nesta entrega. Não deve ser marcado ✔ até sua execução.

2. Avaliação qualitativa da clusterização, número de clusters e métricas

O estudo utilizou uma amostra reprodutível de **250 notícias**, com K-Means e valores `k = 3, 4, 5, 6, 8` para BoW, TF-IDF e Word2Vec. Os documentos foram comparados por **distância cosseno**; a métrica principal foi o Silhouette. As distâncias intra/interclusters são médias de distâncias entre pares de notícias dentro e fora dos grupos. Para o gráfico bidimensional, matrizes esparsas foram primeiro reduzidas por TruncatedSVD e então projetadas com PCA.

Representação	Melhor k testado	Silhouette (cosseno)	Distância intra média	Distância inter média
BoW	8	0,0061	0,8104	0,8649
TF-IDF	8	0,0586	0,8701	0,9281
Word2Vec	3	0,2321	0,1366	0,2004

Interpretação: Word2Vec produziu a melhor separação segundo a métrica Silhouette dentre os valores testados. Entretanto, seus três grupos são amplos e misturam assuntos de diferentes clubes; isso não basta para concluir que os grupos são os mais úteis para leitura humana. A análise de títulos mostra que os oito grupos de TF-IDF conseguem reunir matérias sobre convocação, Palmeiras, Santos, Botafogo e São Paulo, com maior clareza temática em alguns agrupamentos. BoW apresentou separação muito fraca, com Silhouette próximo de zero.

A escolha de **k = 8** para TF-IDF e BoW e **k = 3** para Word2Vec corresponde apenas ao melhor resultado **dentro da grade de valores testados**, não a um número ótimo universal. Os gráficos PCA auxiliam na inspeção, mas a projeção em 2D distorce parte das distâncias do espaço original. Além disso, as distâncias intra/inter de representações diferentes não são diretamente comparáveis por terem geometrias distintas. A interpretação humana dos títulos deve ser considerada junto com as métricas.

Evidências: `resultados/comparacao_silhouette.png`, `resultados/pca_bow.png`, `resultados/pca_tfidf.png`, `resultados/pca_word2vec.png`, `resultados/clusterizacao_exemplos.csv`, `resultados/clusterizacao_metricas.csv`.

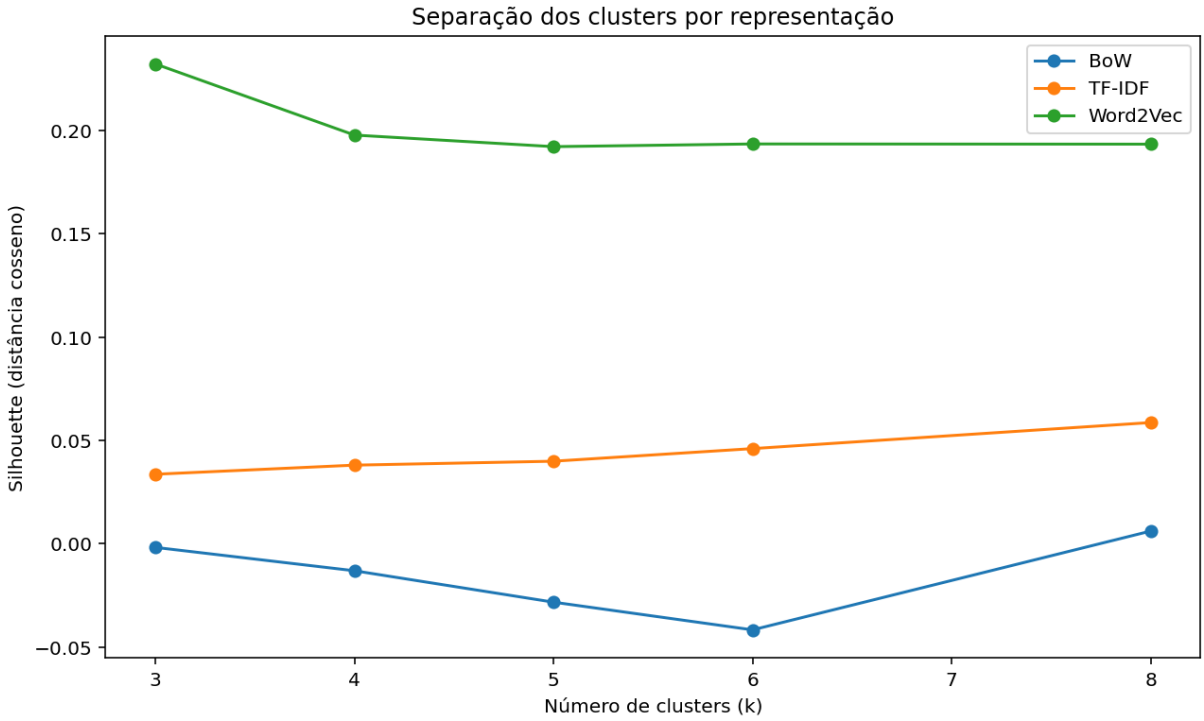


Figura 1 — Silhouette cosseno por representação e número de clusters (250 notícias).

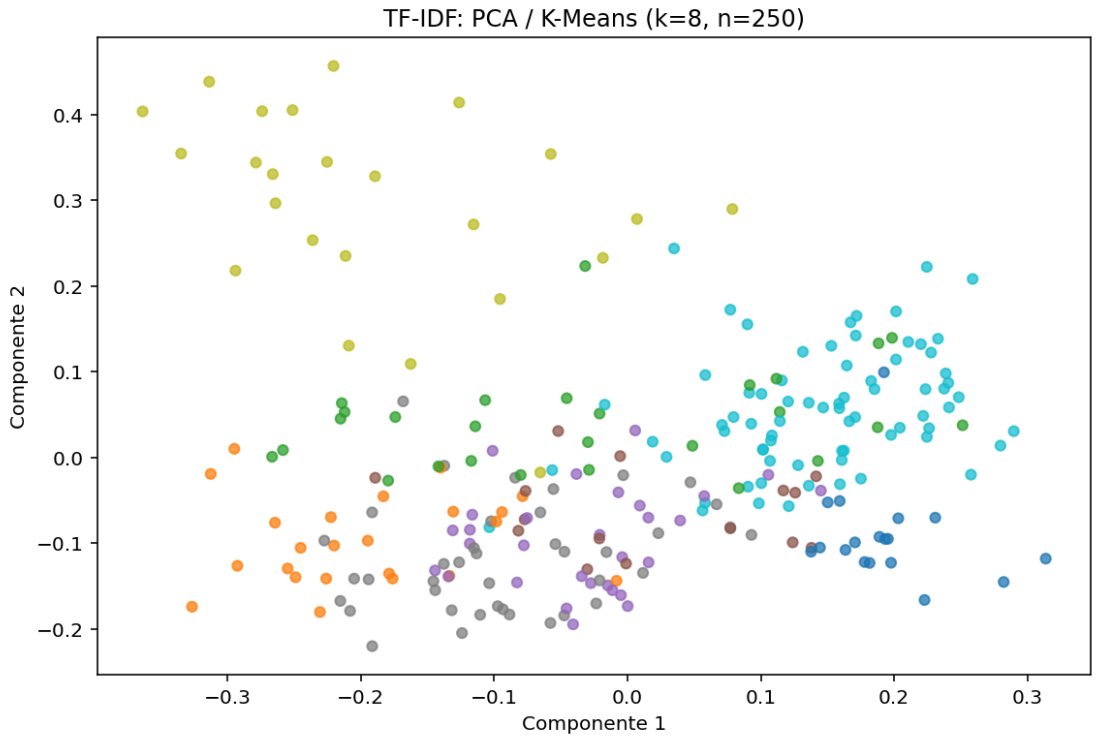


Figura 2 — Projeção PCA dos agrupamentos TF-IDF (k = 8). Visualização aproximada.

3. Busca: qualidade dos top-3 e top-5

Foram executadas **quatro consultas** sobre todas as 500 notícias em cada representação BoW, TF-IDF e Word2Vec, recuperando top-5; o top-3 corresponde às três primeiras posições. As consultas cobrem transferências, resultado e gols, lesões e troca de técnicos. Os resultados e escores de cosseno estão no CSV `busca_top5_com_avaliacao_manual.csv` (60 linhas).

Observações fundamentadas em títulos recuperados:

1. Na consulta por **contratações**, BoW encontrou no topo uma matéria sobre o Palmeiras encerrar a janela sem reforços, enquanto Word2Vec trouxe também notícia sobre o Atlético e apostas na janela. O TF-IDF exibiu na primeira posição uma matéria sobre empréstimo financeiro do Vasco — o termo empréstimo provavelmente induziu uma aproximação lexical, embora não indique transferência de jogador.
2. Na busca por **resultado de jogo e gols**, BoW priorizou uma notícia sobre técnicos no Brasileirão, pouco alinhada à necessidade de placares/gols; TF-IDF trouxe um empate de seis gols entre Coritiba e Athletico entre os primeiros resultados, mais diretamente pertinente. Word2Vec listou matérias de disputas e previsões de resultados, nem sempre resultados concretos.
3. Na consulta de **jogadores lesionados**, BoW retornou inicialmente uma notícia sobre o gramado do Maracanã, que é apenas tangencialmente relacionada ao problema. Word2Vec recuperou diretamente matérias de lesões de Cano e Ignácio, de histórico de lesões no São Paulo e de problemas no joelho de Buta.
4. Na busca por **mudança de treinador**, as três representações recuperaram a matéria sobre os técnicos demitidos no ano. Word2Vec também recuperou a demissão de Luís Castro e a apresentação de Tite pelo Botafogo.

Conclusão provisória: os resultados mostram utilidade real para exploração de notícias, mas **não** devem ser considerados um mecanismo de recomendação pronto para produção, porque há falsos positivos e diferentes interpretações das consultas. Recomenda-se combinar recuperação lexical (TF-IDF/BM25) com reranqueamento semântico e metadados como data, clube e competição. A comparação quantitativa Precision@3 e Precision@5 depende de **revisão humana das 60 posições**: o CSV disponibilizado deixa vazia a coluna `relevancia_manual_0_1_2` e o notebook calcula essas métricas depois do preenchimento.

Limite importante: essas observações derivam de inspeção de títulos e resumos da base, e não substituem uma avaliação formal de relevância com julgamentos independentes.

4. Classificação supervisionada

A classificação prevê a `secao` das notícias. Foram consideradas **493 notícias** pertencentes às 11 seções com pelo menos 10 exemplos, divididas aleatoriamente com estratificação em **369 exemplos de treino** e **124 de teste** (25%). Usou-se regressão logística sobre cada representação e uma linha de base que prevê a classe mais frequente. Não foi utilizada a coluna `secao` como entrada de nenhum classificador.

Representação	Acurácia	F1 macro
BoW + regressão logística	93,55%	0,9385
TF-IDF + regressão logística	90,32%	0,8994
Word2Vec + regressão logística	80,65%	0,7958

Representação	Acurácia	F1 macro
Baseline classe majoritária	12,90%	0,0208

As representações esparsas obtiveram melhor desempenho neste experimento; a regressão logística sobre BoW apresentou a maior acurácia e F1 macro. Isso não demonstra superioridade geral de BoW em PLN: a tarefa de prever a seção de um clube é facilitada pelo fato de o título e o corpo mencionarem frequentemente o nome do próprio clube. Trata-se de possível **vazamento semântico do alvo**, a ser investigado com um teste adicional que remova menções diretas ao clube. O teste estratificado de 25% é um conjunto de notícias não utilizado para ajustar o classificador, mas não garante generalização temporal: um teste com notícias publicadas em dias posteriores seria mais rigoroso.

Foi utilizada uma técnica de **modelo de decisão supervisionado** (regressão logística) e uma representação vetorial baseada em modelo de linguagem de palavras treinado neste corpus (Word2Vec). A comparação com BERTimbau está preparada em código, mas não foi executada nesta análise. Previsões incorretas por notícia foram gravadas no CSV de teste para análise detalhada.

Evidências: `resultados/classificacao_metricas.csv`, `resultados/classificacao_previsoes_teste.csv` e `resultados/classificacao_comparacao.png`.

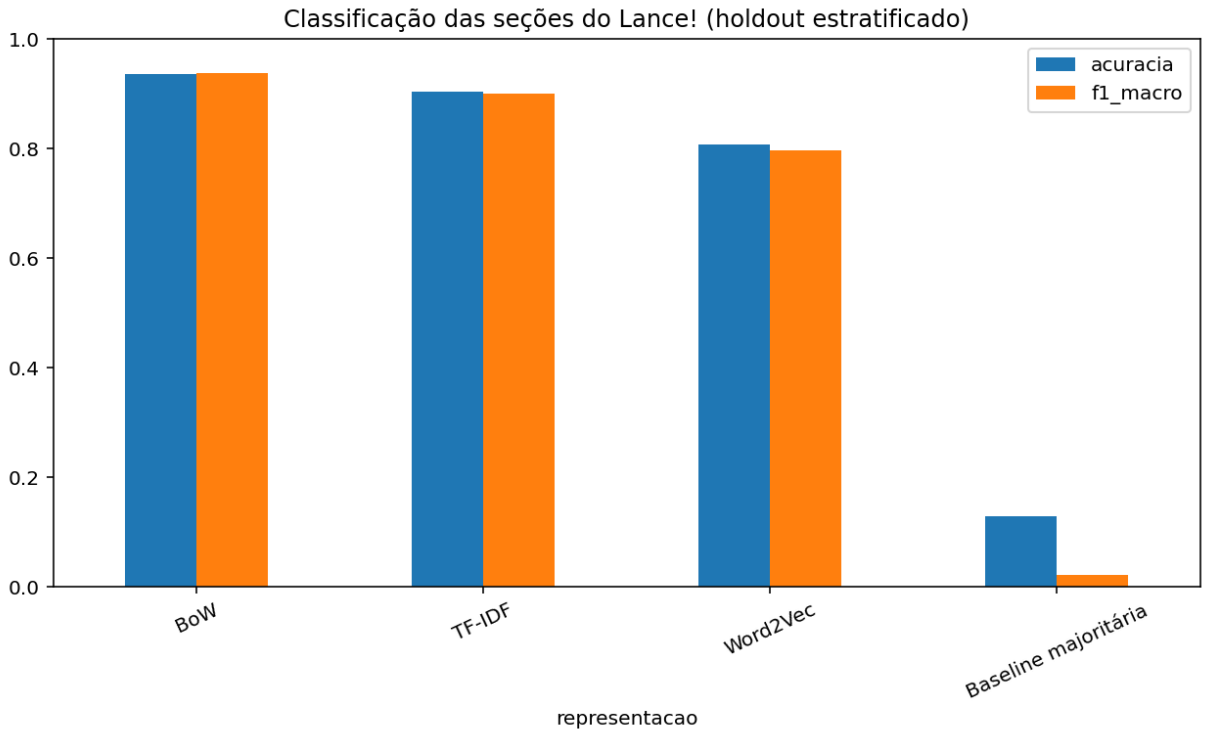


Figura 3 — Resultados de classificação por seção nas notícias de teste.

5. Sentimentos, entidades nomeadas e extração de relações

Sentimentos

A técnica é aplicável como indicador exploratório de tom jornalístico, mas sua interpretação precisa de cuidado: uma derrota ou lesão pode ser narrada de maneira neutra, e o sentimento da notícia não corresponde automaticamente ao sentimento dos torcedores.

Na **execução anterior anexada pelo grupo**, o modelo pré-treinado `cardiffnlp/twitter-xlm-roberta-base-sentiment` classificou **15 notícias** em **10 neutras (66,7%)**, **5 negativas (33,3%)** e **0 positivas (0%)**. As pontuações da categoria vencedora ficaram aproximadamente entre 0,42 e 0,56; a ausência de positivos em 15 notícias não demonstra defeito no algoritmo. A amostra é pequena e o modelo foi concebido para posts de redes sociais, não especificamente para jornalismo esportivo. Exemplos de títulos com termos positivos, como a comemoração de um primeiro gol, foram previstos como neutros, sugerindo necessidade de revisão humana.

O notebook `02_Sentimentos_NER_Relacoes.ipynb` foi **atualizado para 100 notícias selecionadas ao acaso** e permite anotar previsões manualmente. **Esses 100 resultados ainda não estão computados**, porque a execução do modelo requer pesos externos indisponíveis neste ambiente. O relatório **não** reutiliza números da amostra de 15 como se fossem provenientes da de 100.

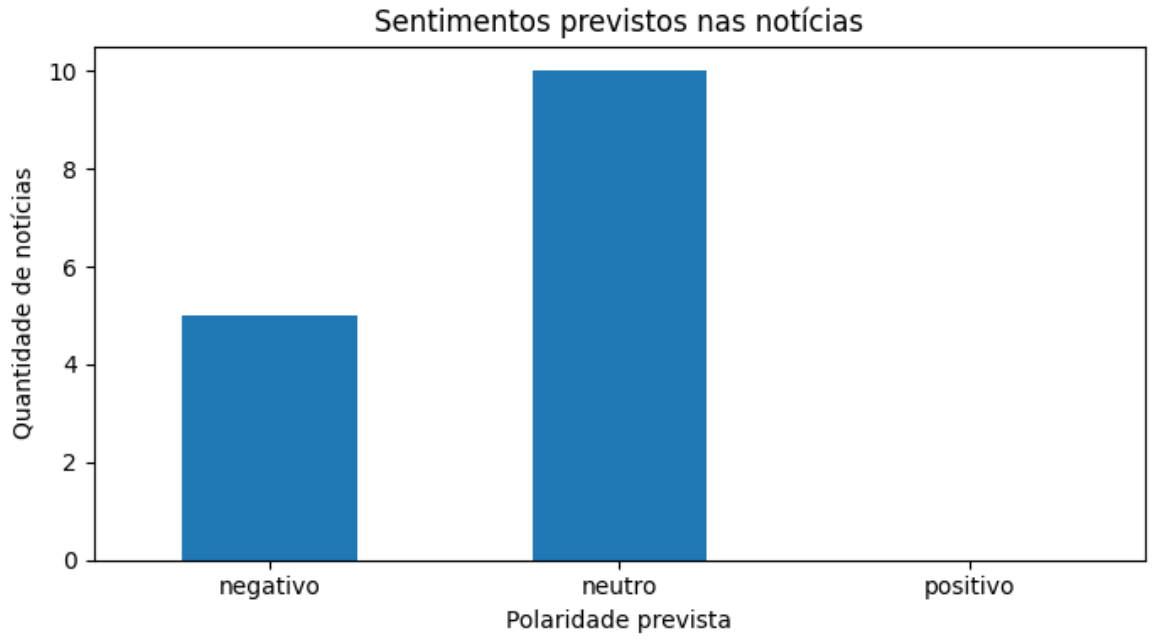


Figura 4 — Resultado prévio de sentimentos sobre 15 notícias. A versão de 100 ainda precisa ser executada.

NER

Na mesma execução anterior, o spaCy `pt_core_news_sm` reconheceu **505 menções de entidades em 25 notícias**: **187 PER**, **161 ORG**, **93 LOC** e **64 MISC**. Exemplos frequentes incluem Flamengo, Fluminense e Palmeiras como organizações. Há ambiguidades e erros: São Paulo pode representar município ou clube; Del Valle apareceu como pessoa em algumas ocorrências, demonstrando a necessidade de correção manual de entidade e categoria.

Relações

O parsing de dependências e regras de sujeito-verbo-objeto/complemento produziram **607 triplas candidatas** em 25 notícias. O grafo ilustrativo previamente gerado tem **28 nós e 20 arestas**. A extração é aplicável para relações como jogador-clube, treinador-clube e resultado/participação em competições, mas nem todas as triplas são corretas ou suficientemente desambiguadas. **Quantidade de triplas não equivale a precisão**. É necessário conferir amostras das frases de origem antes de usar as relações como fatos.

Evidências: `resultados/sentimentos_execucao_anterior_15.csv`, `resultados/sentimentos_execucao_anterior_15.png`, `resultados/grafo_relacoes_execucao_anterior.png`. O notebook atualizado produz novos CSVs de revisão manual ao ser executado.

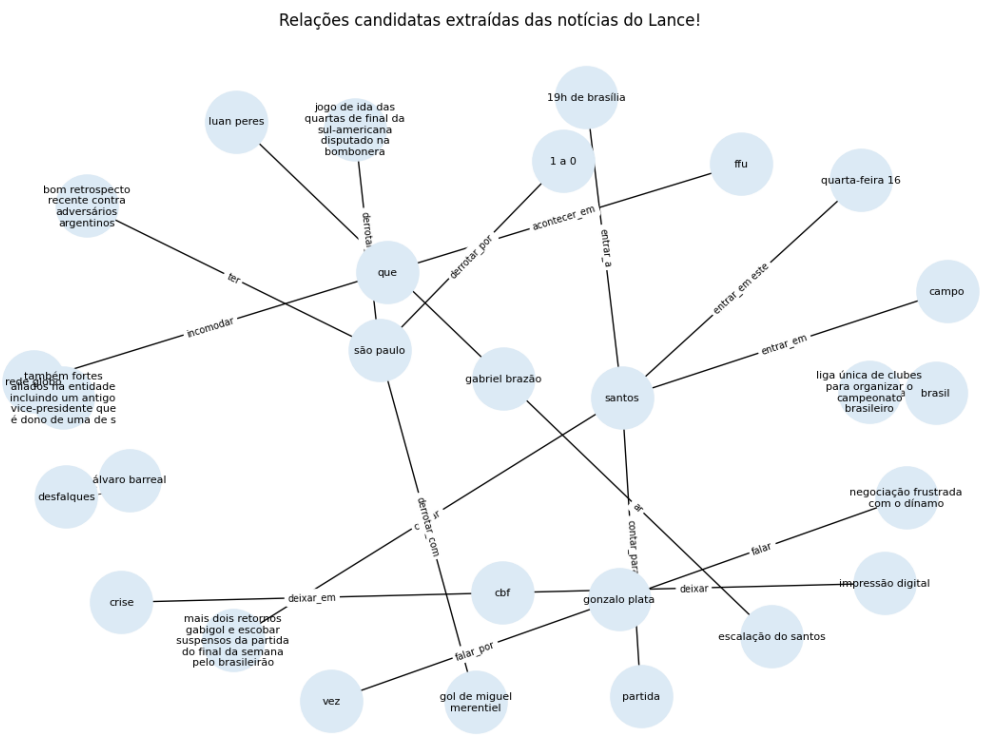


Figura 5 — Grafo ilustrativo de relações candidatas (amostra anterior de 25 notícias).

6. Contribuições para o projeto da Unidade 1

De acordo com o objetivo documentado no repositório, a base do Lance! foi escolhida por conter textos jornalísticos em português, variados clubes e competições, permitindo testar classificação, frequência de termos, entidades, agrupamento de matérias e buscas. As técnicas experimentadas contribuem de modo complementar: agrupamentos revelam temas recorrentes; busca semântica encontra notícias relacionadas a consultas; classificadores ajudam a organizar materiais por seção; sentimentos permitem explorar o tom do conteúdo; NER e relações podem alimentar filtros, catálogos ou grafos de conhecimento.

A combinação que parece mais promissora é **TF-IDF + sinais semânticos + metadados** para pesquisa, **classificação supervisionada** para organização e **spaCy** para extração estruturada com revisão. O projeto é principalmente experimental: há potencial prático, mas ainda faltam avaliação humana sistemática das buscas, validação das entidades/relações, teste de dados novos e eventual comparação efetiva com BERT. Se o objetivo específico apresentado na Unidade 1 for diferente do descrito no README, esta seção deve ser ajustada.

Limitações e próximas verificações antes da entrega definitiva

- Executar a configuração BERTimbau do notebook 01 para completar as colunas BERT da questão 1, registrando o desempenho real.
- Executar o notebook 02 atualizado para **100 notícias** de sentimentos, mantendo 25 para NER/relações.
- Preencher as avaliações manuais das 60 posições de busca, entidades, relações e sentimentos, e calcular precisão nos casos rotulados.
- Substituir texto normalizado por texto original para NER/extração quando possível.

- Revisar seção 6 à luz da proposta original da Unidade 1 e confirmar os critérios de entrega com a professora.

Declaração de uso de IA generativa

Fornecedor: OpenAI. **Modelo:** GPT-6 (ChatGPT). **Uso:** apoio na organização dos requisitos do trabalho, preparação do código dos experimentos e na redação inicial/estrutura deste relatório, a partir do CSV e dos resultados disponíveis. As conclusões sobre pertinência e os rótulos de relevância ainda precisam de conferência pelo grupo.

Prompts do usuário que orientaram esta produção (literalmente): “pode fazer completo conforme o pdf que te mandei no começo”; “tem como aumentar a quantidade?”; “eu preciso rodar o ipynb né, qual arquivo eu uso como base?”; “oq são esses spaCy, `ardiffnlp/twitter-xlm-roberta-base-sentiment` ?”; “e isso o professor utiliza no exemplo da aula 9 tbm?”. A assistência também recebeu o PDF da Unidade 3, o exemplo de parsing/NER/relações da Aula 9, o CSV de notícias e um notebook já executado pelo grupo.

Observação: o grupo deve manter e atualizar esta seção para refletir exatamente as ferramentas, prompts e alterações efetivamente usados antes da submissão.